JAWABAN LATIHAN FORMATIF - PERTEMUAN 6

Persiapan Dataset Citra

1. Kasus Data Leakage

Mengapa salah. Mahasiswa memperbanyak 100 citra menjadi 400 file (rotasi dan pencerminan) *sebelum* split. Setiap citra asli kini punya sekitar 3 turunan yang sangat mirip. Saat 400 file diacak lalu dibagi 80/20, turunan dari citra yang sama tersebar ke train dan test. Test set tidak lagi berisi data yang benar-benar belum pernah dilihat model: model sudah melihat 'kembaran' hampir setiap citra uji. Ini pelanggaran asumsi independensi antara data latih dan data uji (data leakage).

Dampak. Akurasi uji menjadi terlalu optimistis (misalnya 98%) karena model hanya perlu mengenali ulang citra yang pernah dihafal, bukan menggeneralisasi. Di dunia nyata, dengan foto baru, akurasi turun jauh (misalnya 70%). Metrik yang dilaporkan tidak jujur dan penguji skripsi dapat menolaknya.

Alur benar. Split dulu (100 menjadi 80 train / 20 test, idealnya stratified dan berseed tetap), lalu augmentasi dinamis **hanya** pada train memakai torchvision.transforms. Val dan test hanya Resize + Normalize.

2. Kasus Shortcut Learning (Mawar vs Melati)

Hipotesis: model mungkin hanya mengenali lantai keramik cokelat (Mawar) versus tanah basah (Melati). Cara membuktikan secara ilmiah:

a) Uji out-of-distribution (paling meyakinkan). Buat test set baru: Mawar di tanah basah dan Melati di lantai keramik. Jika akurasi anjlok jauh di bawah akurasi asli (bahkan di bawah 50%, yaitu 'terbalik'), model bergantung pada latar.

b) Ablasi / masking. Tutup area bunga dengan blok abu-abu dan prediksi hanya dari latar. Jika model masih akurat, latar sudah cukup sebagai petunjuk. Sebaliknya, tutup latar (segmentasi/crop ketat pada bunga): jika akurasi turun drastis, bunga memang dipakai.

c) Visualisasi atribusi. Grad-CAM atau saliency map: periksa apakah area aktivasi berada di mahkota bunga atau di lantai/tanah.

d) Audit statistik. Korelasikan warna rerata latar dengan label; bila prediksi dapat ditebak hanya dari warna latar (misalnya classifier sederhana pada histogram tepi citra) dengan akurasi tinggi, dataset bias.

Perbaikan. Foto kedua bunga di latar yang sama dan beragam, seimbangkan indoor/outdoor, dan gunakan augmentasi latar (random crop, background replacement) lalu uji ulang.

3. Kasus Pemilihan Tool (Make Sense vs cloud komersial tertutup)

Reproduktibilitas riset. Make Sense gratis, open source (GitHub), tanpa batas kuota, dan mengekspor format standar terbuka (YOLO .txt, VOC XML, COCO JSON). Siapa pun, termasuk penguji dan peneliti lain, dapat membuka hasil anotasi dan mengulang eksperimen tanpa akun berbayar. Tool komersial tertutup berisiko: langganan berakhir, kuota habis, format atau fitur berubah, atau vendor menutup layanan, sehingga anotasi sulit diakses atau diversi-ulang. Versi tool yang terdokumentasi (mis. Make Sense v1.1.0 di Data Card) juga memudahkan replikasi.

Keamanan privasi data. Make Sense berjalan di sisi browser: citra dilabeli secara lokal tanpa harus diunggah ke server pihak ketiga. Pada platform cloud komersial, citra diunggah ke server vendor sehingga perlu diperiksa kebijakan retensi, lokasi server, kepemilikan data, dan kemungkinan dipakai untuk melatih model vendor. Ini penting bila data memuat wajah, plat nomor, atau lokasi pribadi yang tunduk pada aturan perlindungan data pribadi dan persetujuan responden (informed consent).

Catatan keseimbangan. Platform komersial menawarkan kolaborasi tim, kontrol kualitas, dan auto-label; bila dipakai, dokumentasikan versi dan ekspor anotasi ke format terbuka sebagai arsip.