LAPORAN ANALISIS DATASET

Klasifikasi Sampah Daur Ulang: Organik, Anorganik Plastik, Anorganik Logam

Tugas 3 - Curate Dataset & Analisis Bias | Computer Vision and Deep Learning | Nama: [isi] | NIM: [isi]

Catatan: angka jumlah citra, resolusi, perangkat, dan hasil audit pada laporan ini adalah **contoh isian** yang ditandai [ganti]. Gantilah dengan angka dari dataset dan hasil skrip curate_dataset.py milik Anda sebelum dikumpulkan.

BAB I. Deskripsi Domain & Sumber Data

Domain masalah. Pemilahan sampah rumah tangga di tingkat sumber masih dilakukan manual dan sering salah. Sistem klasifikasi citra dapat membantu memilah sampah ke tiga kategori: *organik* (daun, sisa buah), *anorganik plastik* (botol, gelas), dan *anorganik logam* (kaleng, paku). Tugas visual yang dipilih adalah klasifikasi satu label per citra, sehingga format penyimpanan yang dipakai adalah ImageFolder PyTorch.

Sumber data. Data dikumpulkan secara mandiri (primary data collection) memakai kamera ponsel pada resolusi 1080p [ganti], dilengkapi bila perlu dari Kaggle Datasets berlisensi terbuka (CC-BY/MIT/Public Domain) dengan mencantumkan lisensi dan sitasinya. Pengambilan foto memvariasikan sudut (depan, samping 45 derajat, atas), jarak (close-up, medium shot), dan pencahayaan (pagi, siang luar ruangan, malam dengan lampu ruangan).

Etika & privasi. Foto tidak memuat wajah orang atau plat nomor kendaraan. Bila ada, bagian tersebut dikaburkan (blur) atau citra dibuang.

BAB II. Statistik Distribusi Citra & Data Card

2.1 Distribusi per kelas (contoh isian [ganti]):

Kelas	Total	Train (70%)	Val (15%)	Test (15%)
organik	50	35	8	7
anorganik_plastik	50	35	8	7
anorganik_logam	40	28	6	6
Total	**140**	**98**	**22**	**20**

Rasio imbalance = 50 : 40 = 1,25 : 1 (ringan). Pembagian dilakukan **stratified** per kelas dengan seed 42 sehingga proporsi kelas pada train, val, dan test sama. Split dilakukan **sebelum** augmentasi, dan manifest split disimpan agar dapat direplikasi.

2.2 Audit kebersihan. Hasil skrip: diperiksa 140 file [ganti], rusak 0 [ganti], duplikat identik (MD5) 0 [ganti], kandidat near-duplicate (dHash) 0 [ganti]. File rusak dan duplikat dipindahkan ke folder karantina, bukan langsung dihapus, agar dapat diperiksa.

2.3 Data Card (Datasheet for Datasets, Gebru et al., 2021)

Aspek	Isi
1. Motivasi	Menjawab apakah CNN dapat memilah tiga kategori sampah dari foto ponsel dunia nyata. Dikumpulkan dan didanai mandiri oleh mahasiswa.
2. Komposisi	140 citra, 3 kelas (50 / 50 / 40). Resolusi asli 1920x1080 hingga 4032x3024 [ganti]. Format JPG.
3. Pengumpulan	Kamera ponsel [ganti tipe]. Waktu 07.00-19.00 WIB; kondisi: luar ruangan siang, dalam ruangan lampu, teduh sore [ganti].
4. Pra-pengolahan & anotasi	Label berupa nama folder, diberi mandiri dan diverifikasi ulang [bila ada, oleh teman/ahli]. Audit corrupt, deduplikasi MD5 + dHash, split stratified 70/15/15 seed 42.

Aspek	Isi
5. Keterbatasan & bias	Belum mencakup hujan lebat, sampah basah/kotor berat, dan sampah tumpuk. Latar didominasi lantai/tanah sekitar lokasi pengambilan. Jumlah kecil (30-50 per kelas) sehingga hasil perlu dibaca hati-hati.

BAB III. Teknik Augmentasi & Justifikasi Fisis

Augmentasi dilakukan **dinamis di memori hanya pada data train**. Val dan test hanya memakai Resize, ToTensor, dan Normalize (rerata/std ImageNet) agar evaluasi objektif dan tidak terjadi data leakage.

Transformasi	Parameter	Justifikasi fisis
RandomResizedCrop	224, scale 0.8-1.0	Objek sampah muncul dengan jarak dan posisi berbeda dalam bingkai; crop ringan meniru variasi jarak tanpa memotong objek.
RandomHorizontalFlip	p = 0.5	Sampah tidak punya arah kiri-kanan yang bermakna; botol atau kaleng yang dicerminkan tetap objek yang sama. Tidak ada teks yang diandalkan.
RandomRotation	+/- 15 derajat	Sampah diletakkan dengan orientasi acak; rotasi kecil menjaga objek tetap dikenali.
ColorJitter	brightness 0.2, contrast 0.2, saturation 0.2; **hue = 0**	Meniru variasi cahaya pagi/siang/malam. Hue tidak diubah karena warna dapat menjadi pembeda (mis. kaleng logam vs plastik bening), sehingga perubahan hue merusak validitas semantik.
Tidak dipakai: VerticalFlip	-	Sampah di permukaan tidak pernah tampil terbalik secara vertikal pada kamera tampak depan/samping.

BAB IV. Analisis Potensi Bias Visual & Rencana Mitigasi

Model deep learning cenderung memakai jalan pintas (*shortcut learning*). Berikut hasil telaah checklist bias untuk dataset ini:

Risiko bias	Temuan / potensi	Mitigasi
Latar belakang berkorelasi dengan kelas	Sampah organik cenderung difoto di tanah/rumput, plastik di lantai keramik, logam di aspal [ganti sesuai fakta].	Foto setiap kelas di beberapa latar yang sama; tambahkan latar acak; audit rerata warna tepi per kelas dengan bias_audit().
Indoor vs outdoor timpang	Hitung proporsi indoor/outdoor per kelas; target selisih kurang dari 20%.	Lengkapi kelas yang kurang dengan kondisi yang belum ada.
Pencahayaan	Selisih rerata kecerahan antar kelas diuji; ambang peringatan 0.10.	Ambil foto di jam yang sama untuk semua kelas; ColorJitter pada train.
Sudut & jarak kamera	Kelas minoritas cenderung difoto dari satu sudut.	Wajibkan variasi sudut (depan, 45 derajat, atas) per kelas.
Kelas langka / imbalance	Rasio saat ini 1,25:1 (ringan).	WeightedRandomSampler atau weighted CrossEntropyLoss (pilih salah satu, bukan keduanya sekaligus); laporkan F1 per kelas, bukan hanya akurasi.

Uji pembuktian shortcut. Setelah model dilatih (Pertemuan 7), jalankan background_ablation(): bandingkan akurasi pada citra asli dan citra yang bagian tengahnya (objek) ditutup. Jika akurasi tetap tinggi saat objek ditutup, model memakai latar sebagai jalan pintas dan dataset perlu diperbaiki. Pelengkap: uji pada foto objek yang sama di latar baru (out-of-distribution) dan visualisasi Grad-CAM.

Daftar pustaka. Gebru, T. et al. (2021). Datasheets for Datasets. Communications of the ACM, 64(12), 86-92. | Skalski, P. (2024). Make Sense. https://www.makesense.ai/ | PyTorch Documentation. Torchvision Transforms and Datasets API. | NIST (2023). AI Risk Management Framework 1.0.